

基于深度学习与几何优化的激光雷达与鱼眼相机外参标定

万佳辉¹, 吴光强¹

(1.同济大学汽车学院, 上海 201804)

摘要: 外参标定在自动驾驶、智能监控和机器人感知等领域中至关重要。然而, 现有研究多聚焦于激光雷达与针孔相机的标定, 针对激光雷达与鱼眼相机的研究相对较少。为弥补这一空白, 本文提出一种基于深度学习的激光雷达与鱼眼相机外参标定方法, 并引入几何优化策略进行后处理, 以显著提升标定精度。该方法首先利用神经网络预测外参矩阵, 随后通过几何优化对预测结果进行精修。基于 18,335 组图像-点云数据的实验结果表明, 所提出的深度学习模型能将点云对齐误差降低 91.6%, 而结合后处理优化后, 误差可在此基础上进一步减少 52.4%, 充分验证了本方法在实际应用中的高精度、可靠性与鲁棒性。

关键词: 外参标定; 深度学习; 鱼眼相机; 几何优化

中图分类号: U495

文献标志码: A

Extrinsic Calibration of LiDAR and Fisheye Camera Based on Deep Learning and Geometric Optimization

WAN Jiahui¹, WU Guangqiang¹

(1.School of Automotive Studies, Tongji University, Shanghai 201804, China)

Abstract: Extrinsic calibration plays a crucial role in autonomous driving, intelligent surveillance, and robotic perception. However, existing research primarily focuses on the calibration between LiDAR and pinhole cameras, while studies on LiDAR and fisheye cameras remain relatively limited. To fill this gap, this paper proposes a deep learning-based extrinsic calibration method for a LiDAR and a fisheye camera, incorporating a geometric optimization strategy as post-processing to significantly improve calibration accuracy. The proposed method first utilizes a neural network to predict the extrinsic transformation matrix, followed by geometric optimization to refine the predicted results. Experimental evaluations on 18,335 image-point cloud pairs demonstrate that the deep learning model reduces the point cloud alignment error by 91.6%. With the additional geometric post-processing, the error is further reduced by 52.4%, verifying the high accuracy, reliability, and robustness of the proposed approach in practical applications.

Key words: Extrinsic calibration; deep learning; fisheye camera; geometric optimization

近年来, 自动驾驶技术取得了显著进展, 其中环境感知作为核心模块, 直接决定了系统的安全性与可靠性^[1]。多传感器融合已成为提升感知能力的关键手段^[2], 特别是激光雷达与相机的结合, 不仅能够提供高精度的深度信息, 还能增强场景理解能力。然而, 由于各类传感器拥有各自独立的坐标系, 实现数据的有效融合依赖于高精度的外参标定。

传统的标定方法多采用棋盘格、标定框等人工辅助工具^[3], 通常应用于静态环境, 并多在车辆出厂前完成。根据是否使用标定板, 可将其分为有目标和无目标两类方法。前者以棋盘格为代表, 例如 Zhengyou Zhang^[4]构建了经典的相机内参标定框架, 通过多角度采集角点图像求解参数。在此基础上, Qilong Zhang

收稿日期: 2025-07-11

基金项目:

第一作者: 万佳辉 (2000—), 男, 硕士研究生, 主要研究方向为多传感器融合。E-mail: 2332936@tongji.edu.cn

通信作者: 吴光强 (1965—), 男, 教授, 博士生导师, 工学博士, 主要研究方向为汽车非线性动力学、汽车智能控制、智能自主决策以及各种自动变速器技术等。E-mail: wuguangqiang@tongji.edu.cn

等人^[5]引入非线性优化，进一步提高了标定精度。Huaiyu Cai 等人^[6]则设计了新型标定板，结合局部梯度信息与主平面角点信息，显著提升了激光雷达与相机的标定精度。

无目标标定方法主要依赖传感器运动轨迹或环境自然特征估计外参。例如，Klaus H. Strobl 与 Gerd Hirzinger^[7]基于机械臂的预设运动轨迹提出了相机与机械臂的外参求解方法，广泛应用于机器人系统。Chongjian Yuan 等人^[8]提出了一种基于自然场景边缘特征对齐的外参估计方法，实现了亚像素级精度。

尽管静态标定方法在初始部署阶段具有良好效果，但在实际应用中，因机械振动、温度变化、微小碰撞等因素可能导致传感器安装姿态漂移，从而引发外参失准，影响系统感知效果。因此，具备自适应能力的在线外参标定方法逐渐成为研究热点。近年来，深度学习在目标检测^[9]、轨迹预测^[10]等领域的广泛应用，为外参标定提供了新的思路，使得在线标定在动态场景中具备更强的鲁棒性和实时性。

在线标定方法主要分为基于优化与基于深度学习两大类。前者依赖场景中几何或语义特征建立目标函数进行最小化求解。例如，Yufeng Zhu 等人^[11]提出基于互信息优化的语义标定方法；Hao Wu 等人^[12]则融合车道线与车辆信息以增强外参解算稳定性。后者则利用神经网络学习图像与点云间的空间映射关系，直接预测外参参数，避免复杂的特征匹配与优化过程。例如，Nick Schneider 等人提出的 RegNet^[13]将特征提取、匹配与外参回归整合至端到端网络中，实现了实时标定；Ganesh Iyer 等人提出了 CalibNet^[14]，同样具备良好的实时性。后续的 RGGNet^[15]、CalibRCNN^[16]和 LCCNet^[17]等模型进一步提升了外参估计的精度与稳定性。

目前，大部分研究仍聚焦于激光雷达与针孔相机的标定，而针对激光雷达与鱼眼相机之间外参标定的研究较为稀缺。Jack Borer 等人^[18]提出利用单目深度估计与激光雷达几何约束进行优化，但该方法在深度估计阶段可能存在显著误差，影响整体精度。

考虑到鱼眼相机具备超广视角，可有效覆盖近距离盲区，尤其适用于自动驾驶车辆在复杂城市环境中的周边感知。为了直观展示鱼眼相机的优势，如图 1 所示，我们对比了同一物理相机（共享相同内参）在采用鱼眼模型与针孔模型时，对位于同一位置人物的成像效果。结果显示，鱼眼相机模型能够显著提供更宽广的视场，尤其在图像边缘区域，可清晰捕捉到人物的全身像，而针孔相机模型则仅能捕捉到部分区域。这充分表明鱼眼相机能够提供更宽广的视野，减少视觉盲区，对于需要大范围感知的场景具有明显优势。




图 1 鱼眼相机与传统针孔相机成像效果对比

Fig.1 Comparison of Imaging Effects between Fisheye Camera and Traditional Pinhole Camera

本文聚焦于自动跟随车辆中激光雷达与鱼眼相机的外参标定问题，所采用的实验平台如图 2 所示。该平台将鱼眼相机和激光雷达安装在车辆前部，旨在实现对清扫人员的自动跟随，以协助其进行清扫作业。

在本文方法设计中，我们利用同步的图像与点云信息进行神经网络训练，并通过几何优化后处理策略进一步优化预测结果。该方法能够在动态环境下实现高精度外参估计，从而增强自动驾驶系统的环境感知能力与行车安全性。



图 2 实验平台示意图

Fig.2 Schematic Diagram of the Experimental Platform

1 传感器外参标定方法设计

1.1 数据获取与预处理

1) 训练样本构造:

由于逐帧直接标定每对同步图像与点云的外参极具挑战性，本文通过对每一对同步图像与点云数据进行变换，构建了大量训练样本。具体流程如下：

对于每一帧同步数据对 $pair_l = \{I, P_l\}$ ，其中 I 表示鱼眼相机图像， P_l 表示基于激光雷达坐标系下的点云数据，首先利用已知的初始外参矩阵 M_{init} 将 P_l 转换到鱼眼相机坐标系下，得到转换后的点云 P_f ：

$$P_f^{(h)} = M_{init} \cdot P_l^{(h)} \quad (1)$$

其中： $P_f^{(h)}$ 和 $P_l^{(h)}$ 分别表示在激光雷达和鱼眼相机坐标系下的点云数据的齐次坐标形式； $[\cdot]^{(h)}$ 表示齐次坐标表达形式。

以此为基础，通过施加新的外参变换 M_{label} 来生成训练数据。具体变换过程如式（2）和（3）所示：

$$P_{train}^{(h)} = M_{label} \cdot P_f^{(h)} \quad (2)$$

$$P_{train} = [P_{train}^{(h)}]_{1:3} \quad (3)$$

其中： M_{label} 为用于生成训练数据的新外参，其构造方法将在下文阐述； P_{train} 为由 P_f 经 M_{label} 变换后得到的训练点云数据。

通过不断调整 M_{label} 的取值，本文能够构造出大量的训练样本对，即 $pair_{train} = \{I, P_{train}\}$ ，为后续深度学习模型的训练提供充分的数据支持。

接下来介绍如何构造 M_{label} 。该矩阵可由六个参数表示，其中三个参数用于表示旋转向量 $rvec = [a, b, c]$ ，另外三个参数用于表示平移向量 $tvec = [x, y, z]$ 。为了具有更直观的几何意义，旋转向量在本文中采用球坐标表示方式，公式如下：

$$\begin{bmatrix} a \\ b \\ c \end{bmatrix} = \alpha \begin{bmatrix} \sin \theta \cos \varphi \\ \sin \theta \sin \varphi \\ \cos \theta \end{bmatrix} \quad (4)$$

因此, M_{label} 可由六维参数向量 $m_{label} = [\theta, \varphi, \alpha, x, y, z]$ 唯一确定。各参数的取值范围如下:

$$\begin{aligned} 0 &\leq \theta \leq 180^\circ \\ 0 &\leq \varphi < 360^\circ \\ -10^\circ &\leq \alpha \leq 10^\circ \\ -1 &\leq x \leq 1 \\ -1 &\leq y \leq 1 \\ -1 &\leq z \leq 1 \end{aligned} \quad (5)$$

2) 图像数据预处理:

本文采用的原始鱼眼图像分辨率为 $1080 \times 1920 \times 3$ (高 \times 宽 \times 通道)。由于图像中存在显著畸变和边缘黑边, 需进行预处理以提取有效信息区域。具体步骤包括: 构建感兴趣区域掩膜、裁剪有效区域并调整图像尺寸至 $512 \times 512 \times 3$, 从而生成训练图像 I_{train} , 如图 3 所示。




图 3 鱼眼图像的预处理流程图

Fig.3 Preprocessing Workflow of Fisheye Images

3) 点云数据预处理: 几何映射图构建:

为了有效地将点云信息输入深度学习网络, 本文采用几何映射图 (Geometric Mapping Image, GMI) 表示方法, 将三维点云投影为二维三通道图像。

设训练点云数据为 $P_{train} = \{(X_i, Y_i, Z_i) \mid i = 1, 2, 3, \dots, N\}$, 基于 Kannala-Brandt 鱼眼相机投影模型^[19], 构造几何映射图的步骤如下:

$$a_i = \frac{X_i}{Z_i}, b_i = \frac{Y_i}{Z_i} \quad (6)$$

$$r_i = \sqrt{a_i^2 + b_i^2} \quad (7)$$

$$\theta_i = \arctan(r_i) \quad (8)$$

$$\theta_{d_i} = \theta_i \cdot (1 + k_1\theta_i^2 + k_2\theta_i^4 + k_3\theta_i^6 + k_4\theta_i^8) \quad (9)$$

$$\tilde{X}_i = \frac{\theta_{d_i}}{r_i} \cdot a_i, \tilde{Y}_i = \frac{\theta_{d_i}}{r_i} \cdot b_i \quad (10)$$

$$\begin{bmatrix} u_i \\ v_i \\ 1 \end{bmatrix} = \begin{bmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} \tilde{X}_i \\ \tilde{Y}_i \\ 1 \end{bmatrix} \quad (11)$$

随后, 将投影后的像素坐标 (v_i, u_i) 与点云数据 P_{train} 关联, 以构建 GMI , 其中三个通道分别赋值为点云

的归一化坐标：

$$GMI(v_i, u_i) = (\frac{X_i}{X_{max}}, \frac{Y_i}{Y_{max}}, \frac{Z_i}{Z_{max}}) \quad (12)$$

其中： k_1 、 k_2 、 k_3 、 k_4 是鱼眼相机的畸变系数； f_x 、 f_y 、 c_x 、 c_y 是相机内参； X_{max} 、 Y_{max} 、 Z_{max} 为归一化系数，用于限定云投影区域，同时确保 GMI 各通道值的归一化。。

最终， GMI 以 $1080 \times 1920 \times 3$ 的分辨率生成。为了确保 GMI 与 I_{train} 具有相同的分辨率 ($512 \times 512 \times 3$)，需要对其进行与前文图像数据预处理类似的操作（有效区域提取、正方形裁剪和尺度调整）。然而，直接对原始 GMI 进行缩放可能会导致点云信息损失，因此，本文采用相机内参矩阵变换方法，直接从 P_{train} 得到目标尺寸的 GMI_{train} ($512 \times 512 \times 3$)。

其变换过程定义如下：

$$\begin{bmatrix} f'_x & 0 & c'_x \\ 0 & f'_y & c'_y \\ 0 & 0 & 1 \end{bmatrix} = s \begin{bmatrix} f_x & 0 & c_x - x_{offset} \\ 0 & f_y & c_y - y_{offset} \\ 0 & 0 & \frac{1}{s} \end{bmatrix} \quad (13)$$

其中： x_{offset} 、 y_{offset} 分别为沿 x 和 y 轴的平移量； s 是为缩放系数。使用该变换后的内参矩阵，执行公式 (6) - (11)，可以直接生成尺寸为 $512 \times 512 \times 3$ 的 GMI_{train} ，从而最大限度保留点云信息，图 4 展示了两种 GMI_{train} 生成方式的差异：(a)为通过缩放原始 GMI 获得，而(b)是利用变换后的相机内参直接生成。从局部放大区域可以明显看出，方式(a)所得到的点云图存在断裂与稀疏现象，而方式(b)中的点云分布更为连续且密集，显著提升了信息保真度。




图 4 两种不同 GMI_{train} 生成方法的效果对比

Fig.4 Comparison of Results from Two Different GMI_{train} Generation Methods

1.2 深度学习网络

1) 网络结构:

双分支特征提取：本文构建了一种双分支深度神经网络架构，分别用于处理来自鱼眼图像和点云数据的模态信息。其中，图像分支以训练图像 I_{train} 为输入，采用预训练的 ResNet18 网络作为特征提取器，旨在捕捉图像中的纹理、边缘及结构等关键视觉特征^[20]。点云分支则以几何映射图 GMI_{train} 为输入，同样采用 ResNet18 架构提取点云的空间结构信息。

值得注意的是，近年来注意力机制在深度学习中的应用日益广泛^[21]。考虑到 GMI_{train} 的大部分区域由于点云稀疏性而包含较少有效信息，为提升密集区域对最终标定预测的贡献度，本文在点云分支特征提取后引入空间注意力模块，该模块通过计算特征图的全局统计信息，并采用最大-最小归一化策略生成空间注意力图，从而有效增强关键区域的特征表达能力。

对输入特征图 $x \in R^{C \times H \times W}$ ，其空间注意力权重由如下公式计算：

$$AttentionMap(i,j) = \frac{\frac{1}{C} \sum_{c=1}^C |x_{c,i,j}| - \min_{i,j}(\frac{1}{C} \sum_{c=1}^C |x_{c,i,j}|)}{\max_{i,j}(\frac{1}{C} \sum_{c=1}^C |x_{c,i,j}|) - \min_{i,j}(\frac{1}{C} \sum_{c=1}^C |x_{c,i,j}|)} \quad (14)$$

其中： $x_{c,i,j}$ 表示输入特征图在通道 c 位置 (i,j) 的值； C 是输入特征图的总通道数。随后，利用该注意力图对原始特征图进行加权：

$$x'_{c,i,j} = x_{c,i,j} \cdot AttentionMap(i,j) \quad (15)$$

其中： $x'_{c,i,j}$ 为经过注意力加权后的特征图。

通过该注意力机制，可以有效增强点云密集区域的特征表达能力，削弱无效区域的干扰，从而提高点云特征在后续特征融合过程中的贡献。

特征融合与加工：为有效融合图像与点云的跨模态特征信息，本文将两个分支提取的特征图在通道维度进行拼接，并引入额外的卷积模块进行特征精炼，逐步实现多模态信息的融合、降维与优化。

全连接回归层：融合后的特征通过展平处理后输入至回归模块，以预测旋转 $r = [\theta, \varphi, \alpha]$ 和平移参数 $t = [x, y, z]$ 。

图 5 直观展示了本文提出的深度学习网络结构。




图 5 深度学习网络结构

Fig.5 Deep Learning Network Architecture

2) 损失函数:

为提高外参估计的精度，本文设计的损失函数基于点云对齐误差，用于衡量使用预测外参与真实外参分别变换后的点云之间的差异。该损失本质上等价于均方根误差的平方，用于度量点云整体的空间偏差：

$$loss_{lidar} = \frac{1}{N} \|M_{pre}^{-1} P_{train}^{(h)} - M_{label}^{-1} P_{train}^{(h)}\|_F^2 \quad (16)$$

其中： $\|\cdot\|_F^2$ 表示 Frobenius 范数的平方，即矩阵中所有元素的平方和； N 为点云中的总点数； M_{pre} 表示由深度学习模型预测得到的外参变换矩阵，是模型输出的六个参数（旋转和平移）转换而来的；而 M_{label} 为训练样本生成过程中人为设定的真实外参矩阵，用于监督模型的学习。

3) 几何优化:

尽管基于深度学习的外参估计方法在激光雷达与鱼眼相机的标定任务中表现出色，但由于所使用的激光雷达点云较为稀疏，模型在某些特定场景下仍可能出现精度下降的问题。为进一步提升外参估计的准确

性与实用性，本文引入了几何优化策略，以增强点云与图像之间的匹配质量。

具体优化流程如下：定义几何优化阶段的图像-点云对集合为： $\Theta_{post} = \{(I_{post_i}, P_{post_i})\}$ ，其中， I_{post_i} 表示第*i*帧的鱼眼图像， P_{post_i} 表示利用初始外参矩阵 M_{init} 变换后的第*i*帧原始激光雷达点云。

为保证几何优化数据的有效性，必须满足以下条件：背景信息在一定时间窗口内充分暴露，且前景目标在传感器视野内连续可见且未被遮挡。此条件确保前景目标在图像中被准确提取，为点云匹配提供可靠依据。在本文中，跟随人员作为前景目标满足此条件。

首先，需要从 I_{post_i} 提取前景目标。本研究采用基于高斯混合模型的背景/前景分割算法^[22]，并对分割结果进行去畸变处理，以获得更准确的前景区域。前景提取过程可表示为：

$$F_{post_i} = G(I_{post_i}) \quad (17)$$

其中： $G(\cdot)$ 是前景提取算法； F_{post_i} 表示从第*i*帧图像 I_{post_i} 中提取的前景人物区域。

随后，为了从 P_{post_i} 中获取前景目标，采取如下步骤：

$$M_{pre_i} = \mathcal{F}_{net}(\Theta_{post}) \quad (18)$$

$$P_{pre_i}^{(h)} = M_{pre_i}^{-1} P_{post_i}^{(h)} \quad (19)$$

$$P_{fgi} = Cluster(\{P_{pre_i} | p \in F_{post_i}\}) \quad (20)$$

$$P_{fgi}^* = M_{pre_i} P_{fgi} \quad (21)$$

其中： $\mathcal{F}_{net}(\cdot)$ 为所训练的深度学习网络函数； M_{pre_i} 是将 Θ_{post} 输入深度学习模型而获得的外参矩阵； $Cluster(\cdot)$ 表示聚类算法； P_{fgi}^* 为仅包含与前景目标对应的点的最终前景点云。

如图 6 所示，经过上述处理步骤后，原始的图像-点云对 $\Theta_{post} = \{(I_{post_i}, P_{post_i})\}$ 可被优化为数据对 $\Theta_{post}^* = \{(F_{post_i}, P_{fgi}^*)\}$ ，用于后续的优化阶段。




图 6 几何优化中数据提取过程示意图

Fig.6 Illustration of Data Extraction for Geometric Optimization

进一步地，基于前文所述的外参参数表示形式，即 $\theta, \varphi, \alpha, x, y, z$ ，可构建如下优化目标函数：

$$\max_{\theta, \varphi, \alpha, x, y, z} \sum_i \sum_{p \in P_{fgi}^*} \mathbf{1}(\Pi(K \cdot p) \in F_{post_i}) \quad (22)$$

其中： $\Pi(K \cdot p)$ 表示将点 p 通过相机内参投影到图像平面； $\mathbf{1}(\cdot)$ 为指示函数，当投影点落在 F_{post_i} 内时取值为 1，否则为 0。

2 结果分析

2.1 定性评估

为验证所提出深度学习模型在外参估计任务中的实际效果，图 7 展示了多个点云在不同外参条件下投影至图像上的可视化结果。从图中可以观察到，在初始外参条件下，点云投影与图像存在明显的空间偏差；而经过模型预测得到的外参修正后，点云与图像之间的空间对齐效果明显改善，表明模型已有效学习到激光雷达与鱼眼相机之间的几何映射关系。

本文进一步引入几何优化策略以提升最终外参估计的精度。图 8 展示了三种条件下的点云投影对比结果：初始外参、深度学习预测外参以及几何优化后的外参。从图中可以明显看出，几何优化后的点云与图像对齐程度最佳，进一步从视觉角度验证了本文所提出几何优化策略的有效性。




图 7 深度学习校正前后点云投影的可视化对比

Fig.7 Visualization Comparison of Point Cloud Projection Before and After Deep Learning Correction




图 8 几何优化前后点云投影的可视化对比

Fig.8 Visualization Comparison of Point Cloud Projection Before and After Geometric Optimization

2.2 定量评估

为进一步评估模型在外参估计任务中的量化性能，本文使用随机生成的真值外参矩阵 M_{label} 来计算点云对齐损失，并与深度学习模型预测结果进行对比分析。模型推理前的点云对齐损失仿照公式(16)定义，即为均方根误差的平方形式：

$$loss'_{lidar} = \frac{1}{N} \|P_{train}^{(h)} - M_{label}^{-1} P_{train}^{(h)}\|_F^2 \quad (23)$$

其中： N 表示点云中三维点的总数量。

图9展示了共计18335组数据中，深度学习校正前后的点云对齐损失变化情况。结果显示，平均误差由6.517839显著下降至0.548611，误差降低约91.6%，表明模型在学习点云与图像之间的空间几何关系方面具有高度的准确性。

进一步地，图10基于几何优化阶段所使用的图像-点云对集合 $\Theta_{post} = \{(I_{post_i}, P_{post_i})\}$ ，统计了三个阶段的点云对齐误差：初始状态、深度学习预测后以及几何优化后。结果显示：初始平均误差为2.733867，经模型预测后降至0.584133，误差降低78.4%；在此基础上，几何优化进一步将误差降低至0.278217，额外下降52.4%。该结果验证了几何优化策略在提高标定精度方面的实用价值和有效性。

综上所述，本文提出的外参标定方法不仅在视觉层面实现了点云与图像的良好对齐，在定量评估中也展现出优异的准确性与鲁棒性，充分证明其在自动跟随车辆等实际场景中的应用可行性与实用价值。




图9 深度学习前后点云对齐损失变化对比（PCAL 为点云对齐损失的简写）

Fig.9 Comparison of Point Cloud Alignment Loss Before and After Deep Learning
(PCAL: Abbreviation for Point Cloud Alignment Loss)




图10 原始、深度学习与几何优化处理后点云对齐损失对比

Fig.10 Comparison of Point Cloud Alignment Loss Before and After Deep Learning and Geometric Optimization

3 结语

本文提出了一种结合深度学习与几何优化的激光雷达与鱼眼相机外参标定方法，旨在显著提升点云与图像之间的对齐精度。该方法构建了一个基于深度神经网络的回归模型，能够直接从图像与点云数据中预测外参矩阵，并通过精心设计的点云对齐损失函数进行训练，从而有效降低点云在鱼眼图像中的投影误差。在几何优化阶段，引入前景目标提取策略，通过筛选与目标区域对应的点云数据对外参参数进行优化，进一步提升了标定精度。

实验结果表明，该方法在多种环境条件下均表现出良好的泛化能力与鲁棒性，具备在自动驾驶系统中多传感器融合场景下的广泛应用潜力。

未来的研究将着重提升该方法在极端环境（如低照度、动态遮挡等）下的稳定性，并进一步探索与 IMU 等其他传感器的数据融合机制，以提高外参估计的精度。此外，可结合轻量化神经网络的设计，降低模型的计算资源需求，增强其在嵌入式平台与实时系统中的部署效率。

作者贡献说明：

万佳辉：提出研究思路，完成方法设计与实验，实现模型训练，撰写并多次修改论文。

吴光强：负责实验数据审核与技术指导，提供研究方向建议。

参考文献：

- [1] Y. Zhang, A. Carballo, H. Yang, and K. Takeda, "Perception and sensing for autonomous vehicles under adverse weather conditions: A survey," *ISPRS Journal of Photogrammetry and Remote Sensing*, vol. 196, pp. 146–177, Feb. 2023, doi: 10.1016/j.isprsjprs.2022.12.021. Federal Emergency Management Agency. Multi-hazard loss estimation methodology hurricane model [EB/OL]. [2008-10-30]. <http://www.fema.gov/library/viewRecord.do?&=303>.
- [2] B. Yang, J. Li, and T. Zeng, "A Review of Environmental Perception Technology Based on Multi-Sensor Information Fusion in Autonomous Driving," *WEVJ*, vol. 16, no. 1, p. 20, Jan. 2025, doi: 10.3390/wevj16010020. VICKERY P J, TWISDALE L A, MONTPELLIER P, et al. Hurricane vulnerability and risk analysis of the VINLEC transmission and distribution system[M]. Washington D C: Applied Research Associates Inc, 1996.
- [3] Y. Wang, J. Li, Y. Sun, and M. Shi, "A Survey of Extrinsic Calibration of LiDAR and Camera," in *Proceedings of 2021 International Conference on Autonomous Unmanned Systems (ICAUS 2021)*, vol. 861, M. Wu, Y. Niu, M. Gu, and J. Cheng, Eds., in *Lecture Notes in Electrical Engineering*, vol. 861., Singapore: Springer Singapore, 2022, pp. 933–944. doi: 10.1007/978-981-16-9492-9_92. WALKER G R. Report on cyclone "Tracy": effect on buildings[R]. North Queensland: James Cook University, 1975.
- [4] Z. Zhang, "A flexible new technique for camera calibration," *IEEE Trans. Pattern Anal. Machine Intell.*, vol. 22, no. 11, pp. 1330–1334, Nov. 2000, doi: 10.1109/34.888718.
- [5] Q. Zhang and R. Pless, "Extrinsic calibration of a camera and laser range finder (improves camera calibration)".
- [6] H. Cai, W. Pang, X. Chen, Y. Wang, and H. Liang, "A Novel Calibration Board and Experiments for 3D LiDAR and Camera Calibration," *Sensors*, vol. 20, no. 4, p. 1130, Feb. 2020, doi: 10.3390/s20041130.
- [7] K. Strobl and G. Hirzinger, "Optimal Hand-Eye Calibration," in *2006 IEEE/RSJ International Conference on Intelligent Robots and Systems*, Beijing, China: IEEE, Oct. 2006, pp. 4647–4653. doi: 10.1109/IROS.2006.282250.
- [8] C. Yuan, X. Liu, X. Hong, and F. Zhang, "Pixel-Level Extrinsic Self Calibration of High Resolution LiDAR and Camera in Targetless Environments," *IEEE Robot. Autom. Lett.*, vol. 6, no. 4, pp. 7517–7524, Oct. 2021, doi: 10.1109/LRA.2021.3098923.
- [9] J. Deng, X. Xuan, W. Wang, Z. Li, H. Yao, and Z. Wang, "A review of research on object detection based on deep learning," *J. Phys.: Conf. Ser.*, vol. 1684, no. 1, p. 012028, Nov. 2020, doi: 10.1088/1742-6596/1684/1/012028.

-
- [10] X. Wang, Q. Luo, K. Liu, R. Mao, and G. Wu, "Deep Learning Method Based on Multiscale Enhanced Feature Fusion for Vehicle Behavior Prediction," *IEEE Internet Things J.*, vol. 12, no. 7, pp. 9142–9155, Apr. 2025, doi: 10.1109/JIOT.2024.3508034.
- [11] Y. Zhu, C. Li, and Y. Zhang, "Online Camera-LiDAR Calibration with Sensor Semantic Information," in *2020 IEEE International Conference on Robotics and Automation (ICRA)*, Paris, France: IEEE, May 2020, pp. 4970–4976. doi: 10.1109/ICRA40945.2020.9196627.
- [12] H. Wu, Y. Liu, H. Huang, J. Li, Q. Lin, and S. Liu, "Targetless External Reference Calibration of LiDAR and Camera in Autonomous Driving Environment," *IEEE Trans. Instrum. Meas.*, vol. 73, pp. 1–9, 2024, doi: 10.1109/TIM.2024.3472904.
- [13] N. Schneider, F. Piewak, C. Stiller, and U. Franke, "RegNet: Multimodal Sensor Registration Using Deep Neural Networks," Jul. 11, 2017, arXiv: arXiv:1707.03167. doi: 10.48550/arXiv.1707.03167.
- [14] G. Iyer, R. K. Ram, J. K. Murthy, and K. M. Krishna, "CalibNet: Geometrically Supervised Extrinsic Calibration using 3D Spatial Transformer Networks," in *2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, Madrid: IEEE, Oct. 2018, pp. 1110–1117. doi: 10.1109/IROS.2018.8593693.
- [15] K. Yuan, Z. Guo, and Z. J. Wang, "RGGNet: Tolerance Aware LiDAR-Camera Online Calibration With Geometric Deep Learning and Generative Model," *IEEE Robot. Autom. Lett.*, vol. 5, no. 4, pp. 6956–6963, Oct. 2020, doi: 10.1109/LRA.2020.3026958.
- [16] J. Shi et al., "CalibRCNN: Calibrating Camera and LiDAR by Recurrent Convolutional Neural Network and Geometric Constraints," in *2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, Las Vegas, NV, USA: IEEE, Oct. 2020, pp. 10197 – 10202. doi: 10.1109/IROS45743.2020.9341147.
- [17] X. Lv, B. Wang, D. Ye, and S. Wang, "LCCNet: LiDAR and Camera Self-Calibration using Cost Volume Network," Apr. 24, 2021, arXiv: arXiv:2012.13901. doi: 10.48550/arXiv.2012.13901.
- [18] J. Borer, J. Tschirner, F. Ölsner, and S. Milz, "Continuous Online Extrinsic Calibration of Fisheye Camera and LiDAR," Jun. 22, 2023, arXiv: arXiv:2306.13240. doi: 10.48550/arXiv.2306.13240.
- [19] J. Kannala and S. S. Brandt, "A generic camera model and calibration method for conventional, wide-angle, and fish-eye lenses," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 28, no. 8, pp. 1335–1340, Aug. 2006, doi: 10.1109/TPAMI.2006.153.
- [20] K. He, X. Zhang, S. Ren, and J. Sun, "Deep Residual Learning for Image Recognition," in *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Las Vegas, NV, USA: IEEE, Jun. 2016, pp. 770–778. doi: 10.1109/CVPR.2016.90.
- [21] D. Soydaner, "Attention Mechanism in Neural Networks: Where it Comes and Where it Goes," *Neural Comput & Applic*, vol. 34, no. 16, pp. 13371–13385, Aug. 2022, doi: 10.1007/s00521-022-07366-3.
- [22] Z. Zivkovic, "Improved adaptive Gaussian mixture model for background subtraction," in *Proceedings of the 17th International Conference on Pattern Recognition, 2004. ICPR 2004.*, Cambridge, UK: IEEE, 2004, pp. 28–31 Vol.2. doi: 10.1109/ICPR.2004.1333992.